

**UNIVERSIDAD NACIONAL DE ASUNCIÓN
FACULTAD POLITÉCNICA**



CIENCIA DE DATOS

**FASE 1 - COMPRENSIÓN, PREPARACIÓN Y ANÁLISIS
EXPLORATORIO**

Tema: Evaluar si existen diferencias salariales significativas entre hombres y mujeres que tienen empleo (2025).

Integrantes (Grupo 8):

- Bruna Aurelia González Romero.
- Karen Yamila Fischer Lesme.
- Marcos Ezequiel Gonzalez Lovera.

Profesora de Cátedra: Dra. Margarita Ruiz Olazar.

Carrera: Ingeniería en Informática.

SAN LORENZO - PARAGUAY

2026

Índice

1. Comprensión del Problema	2
1.1. Contexto y Descripción del Problema	2
1.2. Pregunta de Investigación	2
1.3. Objetivo General	2
1.4. Objetivos Específicos	2
1.5. Importancia de la Investigación	3
2. Comprensión y Selección de los Datos	3
3. Limpieza y Transformación de los Datos	4
4. Análisis Univariado y Bivariado	5
4.1. Análisis Univariado: Métricas de Tendencia Central y Dispersión . . .	5
4.2. Análisis Univariado: Frecuencias Categóricas	5
4.3. Análisis Bivariado: Comparación de Grupos (Numérica vs. Categórica)	6
4.4. Análisis Bivariado: Distribuciones Cruzadas (Categórica vs. Categórica)	6
4.5. Análisis Bivariado: Numérica frente a Numérica	7
5. Etapa 5 - Análisis descriptivo y exploratorio	7
5.1. Gráfico 1: Distribución del Ingreso Principal (Histograma)	8
5.2. Composición de la Fuerza Laboral por Área y Sexo (Barras Comparativo)	9
5.3. Dispersión del Ingreso por Género (Boxplot)	10
5.4. Serie Temporal (Requisito estricto de la rúbrica)	11
5.5. Relación entre Edad e Ingreso Principal (Scatterplot)	11
5.6. Densidad y Distribución del Ingreso por Área Geográfica (Violin Plot)	12
5.7. Mediana Salarial Cruzada por Género y Zona (Barras de Estimación)	13
5.8. Matriz de Correlación (Heatmap)	14
6. Patrones y Anomalías Detectadas	14
7. Hipótesis Preliminares (Hacia la Fase 2)	15
8. Conclusión de la Fase 1	15
9. Declaración de Uso de Asistentes de IA	16
10. Bibliografía y Recursos	16

1. Comprensión del Problema

1.1. Contexto y Descripción del Problema

A pesar de los avances normativos y sociales, la desigualdad de ingresos entre géneros sigue siendo un desafío persistente en el mercado laboral latinoamericano y paraguayo. A simple vista, se observa una disparidad en las retribuciones económicas entre géneros; sin embargo, es necesario determinar si estas diferencias son estadísticamente significativas y si persisten al considerar otros factores determinantes como el nivel educativo, las horas trabajadas, la zona de residencia (urbana/rural) y la rama de actividad u ocupación, evitando sesgos por variables confusoras. El presente proyecto aborda la economía laboral y la equidad de género utilizando los microdatos de la Encuesta Permanente de Hogares Continua (EPHC 2025) elaborada por el Instituto Nacional de Estadística (INE).

1.2. Pregunta de Investigación

El proyecto busca responder, mediante evidencia empírica, a las siguientes interrogantes:

1. ¿Existe brecha salarial entre hombres y mujeres ocupados según la EPHC 2025?
2. ¿La brecha persiste al observar la distribución completa comparada entre regiones urbanas y rurales?
3. ¿Qué tanto influyen la edad, la educación, el área y la informalidad al predecir el salario?

1.3. Objetivo General

Analizar si existen diferencias significativas en la distribución salarial entre hombres y mujeres ocupados en Paraguay, evaluando el impacto de factores demográficos e informales mediante pruebas de hipótesis y análisis multivariado sobre la EPHC 2025.

1.4. Objetivos Específicos

- **OE 1:** Realizar la limpieza y estructuración del conjunto de datos de la EPHC 2025, filtrando a la población ocupada con registro de salario neto mensual (Fase 1).

- **OE 2:** Agrupar los datos por género y ejecutar un análisis exploratorio (EDA) comparando el ingreso promedio mediante histogramas y boxplots segmentados por área urbana/rural (Fase 1).
- **OE 3:** Formular y contrastar formalmente el test de hipótesis principal utilizando estadística inferencial (Prueba U de Mann-Whitney y ANOVA/Kruskal-Wallis) para evaluar la varianza salarial considerando múltiples factores (Fase 2).
- **OE 4:** Implementar modelos de Machine Learning (ej. Regresión Lineal o Random Forest) para predecir el nivel de salario y cuantificar la influencia real de variables como la educación y el género (Fase 3).

1.5. Importancia de la Investigación

Este estudio permite aportar evidencia empírica objetiva para visibilizar la desigualdad de ingresos. Entender si la brecha es puramente por género o si está mediada por la zona, la educación o la informalidad, es crucial para orientar políticas públicas laborales y económicas mucho más precisas y efectivas.

2. Comprensión y Selección de los Datos

- **Fuente de Datos:** Microdatos oficiales de la EPHC 2025 (Archivo: REG02_EPHC_ANUAL_2025.csv) provistos por el INE Paraguay.
- **Unidad de Análisis:** Personas ocupadas (individuos mayores de 18 años con empleo formal o informal reportado en la encuesta).
- **Variables Principales:** Se seleccionaron los atributos clave propuestos:
Salario neto principal (e01aimde).
Género (P06).
Edad (P02).
Años de estudio (añoest).
Área geográfica (AREA).
Condición ocupacional (A01).
Departamento (DPTO).
- **Perfilado Inicial:** El archivo original contenía 55,934 filas y 213 columnas. Durante la exploración, se detectó que el INE codifica los valores faltantes como espacios en blanco tipados como texto, lo cual exigió un pre-procesamiento algorítmico riguroso para cuantificar el porcentaje de nulos reales antes de la limpieza.

Cuadro 1: Diccionario de Datos Perfilado - EPHC 2025

Variable Original	Nombre Limpio	Descripción	Tipo	Rango o Categorías	% Faltantes
DPTO	departamento	Departamento	Categorica	0 a 15	0.00
AREA	area	Área de residencia	Categorica	1=Urbana, 6=Rural	0.00
P02	edad	Edad en años	Numérica	0 a 99+	0.00
P06	sexo	Sexo	Categorica	1=Hombre, 6=Mujer	0.00
añoest	anios_estudio	Años de estudio aprobados	Numérica	0 a 18+	5.76
A01	ocupado	Condición de ocupación	Categorica	1 a 4	15.82
e01aimde	ingreso_principal	Ingreso principal deflacionado	Num. Continua	Mín: 0, Máx: Variable	0.00

Este cuadro define las variables que estructuran el análisis, revelando la presencia de datos faltantes en variables críticas como `anios_estudio` y `ocupado`, lo que justifica el proceso de limpieza posterior para asegurar la calidad de los resultados.

3. Limpieza y Transformación de los Datos

El proceso se ejecutó de forma íntegramente reproducible mediante Python. Se aplicaron los siguientes pasos, documentados en la bitácora:

1. **Normalización y Filtrado:** Conversión de variables a tipos numéricos. Se filtró estrictamente a individuos mayores de 18 años que declararon estar ocupados (`A01 == 1`), eliminando a inactivos y menores de edad (32,821 registros removidos).
2. **Depuración de Salarios:** Se eliminaron ingresos nulos o iguales a cero (8,545 registros) que no aportan al cálculo real de la brecha.
3. **Tratamiento de Outliers:** Para evitar la distorsión matemática, se removieron los valores atípicos extremos superando el Percentil 99.

El **conjunto de datos final** quedó constituido por **14,422 registros**, exportados como `dataset_limpio_fase1.csv`.

Cuadro 2: Bitácora de Decisiones: Limpieza y Transformación

ID	Paso	Registros afectados	Justificación
0	Renombrar columnas	0	Facilitar manipulación y cumplir PEP8
1	Eliminar registros duplicados exactos	0	Evitar sobre-representación de datos sesgados
2	Filtrar ocupados <18 años	32821	Unidad de análisis de la investigación
3	Eliminar ingresos nulos/cero	8545	Ingresos nulos o cero no aplican para calcular brecha salarial
4	Eliminar Outliers (<Percentil 99)	146	Eliminar ingresos imposibles o que distorsionan gravemente la varianza
5	Crear variables derivadas (Labels)	0	Mejorar legibilidad en visualizaciones (EDA)
Total de registros iniciales crudos:			55,934
Total de registros finales para análisis:			14,422

La bitácora cuantifica la depuración del dataset, destacando la reducción significativa de registros para aislar únicamente a la población ocupada y con ingresos válidos, garantizando así un análisis basado en datos consistentes.

4. Análisis Univariado y Bivariado

4.1. Análisis Univariado: Métricas de Tendencia Central y Dispersión

El estudio descriptivo de la variable *Ingreso Principal* arroja una **Media de 2,629,367 Gs.** y una **Mediana de 2,090,371 Gs.** Al evaluar la forma de la distribución, se obtuvo un coeficiente de asimetría de 2.23 (sesgo positivo pronunciado) y una curtosis de 7.64. Estos valores confirman una distribución altamente leptocúrtica y asimétrica, donde la media aritmética se ve arrastrada por los valores extremos de los segmentos de mayores ingresos. En consecuencia, se determina que la **mediana es el estimador de tendencia central más robusto y representativo** para la población analizada.

4.2. Análisis Univariado: Frecuencias Categóricas

La muestra analizada (N=14,422) presenta la siguiente distribución sociodemográfica:

Cuadro 3: Distribución de Frecuencias: Sexo y Área

Variable	Absoluta	Relativa (%)
Sexo		
Hombre	7,328	50.81
Mujer	7,094	49.19
Área		
Urbana	8,332	57.77
Rural	6,090	42.23

La tabla refleja una distribución casi paritaria entre géneros, con una ligera mayoría urbana en la fuerza laboral ocupada, lo cual contextualiza el alcance de los resultados del estudio.

4.3. Análisis Bivariado: Comparación de Grupos (Numérica vs. Categórica)

A continuación, se presentan los estadísticos del ingreso principal (en Gs.) segmentados por género y área:

Cuadro 4: Estadísticos de Ingreso según Género y Área

Grupo	Count	Media	Std	Mín	25 %	Mediana	75 %	Máx
<i>Segmentación por Género</i>								
Hombre	7,328	2,932,283	2,510,086	833	1,200,000	2,509,045	3,624,435	19,841,176
Mujer	7,094	2,316,460	2,176,646	454	798,273	1,797,408	3,000,000	18,918,162
<i>Segmentación por Área</i>								
Rural	6,090	2,001,359	2,079,301	454	597,416	1,468,398	2,795,968	19,841,176
Urbana	8,332	3,088,389	2,465,778	833	1,494,612	2,692,412	3,914,171	18,918,162

Los estadísticos descriptivos ponen de manifiesto una brecha salarial visible donde los hombres y residentes urbanos perciben ingresos medianos y máximos superiores, lo que sugiere disparidades que merecen un análisis inferencial profundo.

4.4. Análisis Bivariado: Distribuciones Cruzadas (Categórica vs. Categórica)

Tablas de contingencia del mercado laboral según el área de residencia y sexo:

Cuadro 5: Distribución Relativa por Género y Área (en %)

Sexo	Freq. Relativa por Fila		Freq. Relativa por Columna	
	Rural	Urbana	Rural	Urbana
Hombre	48.20 %	51.80 %	58.00 %	45.56 %
Mujer	36.06 %	63.94 %	42.00 %	54.44 %

Existe una marcada diferenciación en la inserción laboral: las mujeres predominan en áreas urbanas, mientras que los hombres mantienen una mayor presencia en sectores rurales, evidenciando una segmentación geográfica según el género.

4.5. Análisis Bivariado: Numérica frente a Numérica

Para evaluar la intensidad y dirección de las relaciones entre las variables cuantitativas, se calcularon las matrices de correlación de Pearson (relaciones lineales) y Spearman (relaciones no lineales basadas en rangos):

Cuadro 6: Matrices de Correlación: Pearson y Spearman

Pearson	Ingreso	Edad	Años Estudio
Ingreso	1.000	-0.123	0.431
Edad	-0.123	1.000	-0.432
Años Estudio	0.431	-0.432	1.000
Spearman	Ingreso	Edad	Años Estudio
Ingreso	1.000	-0.190	0.493
Edad	-0.190	1.000	-0.420
Años Estudio	0.493	-0.420	1.000

La correlación positiva entre los años de estudio y el ingreso confirma el impacto del capital humano, mientras que la correlación negativa con la edad sugiere que, en el contexto actual, la formación académica es un predictor más robusto que la experiencia cronológica.

5. Etapa 5 - Análisis descriptivo y exploratorio

En esta sección se presentan 8 visualizaciones distintas que exploran la distribución de los datos, las relaciones bivariadas y multivariadas, con el fin de identificar patrones y anomalías en torno a la brecha salarial observada en la población ocupada.

5.1. Gráfico 1: Distribución del Ingreso Principal (Histograma)




Figura 1: Distribución del Ingreso Principal (Gs.)

El histograma y la curva de densidad (KDE) evidencian una marcada asimetría positiva (sesgo a la derecha). Se observa una alta concentración de trabajadores en el rango inicial (picos de frecuencia entre los 0 y 2.5 millones de Guaraníes), seguido por una larga cola hacia la derecha que se extiende hasta los 20 millones. Esto se ve reflejado en las líneas de referencia: la Mediana (2.090.371 Gs.) se ubica más a la izquierda y representa de forma más realista el ingreso de la masa salarial, mientras que la Media (2.629.367 Gs.) se desplaza hacia la derecha debido al efecto de arrastre de los salarios más altos, justificando plenamente el uso de estadísticos y pruebas no paramétricas.

5.2. Composición de la Fuerza Laboral por Área y Sexo (Barras Comparativo)




Figura 2: Composición de la Población Ocupada por Área y Sexo

El gráfico de barras comparativo revela diferencias estructurales interesantes en la composición de la fuerza laboral según el área geográfica. En el área urbana, la muestra refleja una mayor participación de mujeres ocupadas (4.536) en comparación con los hombres (3.796). Por el contrario, en el área rural, la tendencia se invierte de manera marcada, registrando una predominancia de trabajadores masculinos (3.532) frente a las mujeres ocupadas (2.558), lo que sugiere una mayor invisibilización o menor inserción formal de la mujer en las actividades económicas del sector primario o rural.

5.3. Dispersión del Ingreso por Género (Boxplot)




Figura 3: Boxplot: Brecha Salarial por Género

El diagrama de caja (boxplot) evidencia de forma visual la brecha salarial de género. La línea central de cada caja (que representa la mediana) muestra que los hombres perciben una retribución mayor en comparación con las mujeres. Asimismo, la caja superior y los bigotes de los hombres se extienden hacia valores más altos, y la densidad de valores atípicos (outliers) se eleva con mayor frecuencia hacia los 20 millones de Guaraníes en el sector masculino, lo que confirma la existencia de un techo salarial más elevado para los hombres en esta muestra.

5.4. Serie Temporal (Requisito estricto de la rúbrica)




Figura 4: Evolución del Ingreso Medio por Trimestre

La serie temporal refleja la evolución de la media salarial de la población ocupada a lo largo de los cuatro trimestres del año 2025. Se observa de manera persistente que la línea que representa a los hombres se mantiene consistentemente por encima de la de las mujeres en todos los trimestres, oscilando los ingresos masculinos cerca de los 2.9 a 3.0 millones de Guaraníes, mientras que los femeninos se ubican entre los 2.2 y 2.4 millones. Esto descarta que la brecha sea un fenómeno estacional aislado, consolidándose como una constante estructural durante todo el año.

5.5. Relación entre Edad e Ingreso Principal (Scatterplot)




Figura 5: Scatterplot: Edad vs. Ingreso

El diagrama de dispersión (scatterplot) permite visualizar la distribución simultánea de la edad frente al ingreso principal, distinguiendo por género. Se observa

que la mayor concentración de ingresos altos se densifica en el rango etario productivo central (entre los 35 y 55 años). Asimismo, al observar los puntos ubicados en los tramos superiores del eje vertical (ingresos superiores a los 10 millones de Gs.), se constata una mayor presencia visual de color rosado (hombres) en comparación con el verde azulado (mujeres), lo que refuerza de manera gráfica la disparidad en el acceso a los techos salariales más altos a lo largo de las diferentes etapas de la vida laboral.

5.6. Densidad y Distribución del Ingreso por Área Geográfica (Violin Plot)




Figura 6: Violin Plot: Distribución por Área y Sexo

El diagrama de violín permite observar simultáneamente la densidad y los cuartiles de la distribución salarial. En la zona urbana, los "violines" se estiran notablemente más hacia la parte superior y muestran una base más ensanchada, lo que evidencia una mayor dispersión y desigualdad interna en los ingresos. En contraste, en la zona rural, la densidad se comprime fuertemente en la base inferior, reflejando salarios más homogéneos pero deprimidos. Asimismo, al comparar las divisiones internas, se advierte que la mitad superior en ambos sexos y zonas siempre muestra una mayor prominencia masculina, corroborando la brecha salarial observada en los tramos de mayores ingresos.

5.7. Mediana Salarial Cruzada por Género y Zona (Barras de Estimación)




Figura 7: Barras de Mediana: Género y Área

El gráfico de barras de medianas cruzadas evidencia de manera contundente la doble penalización estructural en el mercado laboral paraguayo: el cruce entre género y zona geográfica. El grupo con la mediana salarial más alta corresponde a los hombres en zona urbana (2.988.696 Gs.), seguidos por las mujeres en zona urbana y los hombres en zona rural. En el extremo de mayor vulnerabilidad económica se encuentran las mujeres rurales, cuya mediana apenas alcanza 1.009.222 Gs. Esto demuestra que las brechas de ingresos no operan de forma aislada, sino que se potencian negativamente cuando se intersectan la condición de género y la ruralidad.

5.8. Matriz de Correlación (Heatmap)




Figura 8: Heatmap de Correlación

La matriz de correlación de Spearman evidencia la fuerza de las asociaciones no lineales entre las variables cuantitativas del estudio. Destaca la correlación positiva moderada de 0.49 entre los años de estudio y el ingreso principal, lo que confirma estadísticamente que a mayor acumulación de capital humano, mayores son las retribuciones económicas esperadas. Por otro lado, la relación entre la edad y el ingreso muestra un coeficiente levemente negativo de -0.19, indicando que la sola acumulación de edad biológica no tracciona incrementos salariales automáticos. Asimismo, se observa una correlación negativa moderada (-0.42) entre la edad y los años de estudio, lo que refleja un efecto cohorte donde las generaciones más jóvenes poseen, en promedio, mayor cantidad de años de instrucción formal acumulada que las generaciones mayores en la fuerza laboral.

6. Patrones y Anomalías Detectadas

1. **Brecha Salarial Absoluta:** Las distribuciones de ingresos (Boxplots y Violines) revelan que los hombres perciben una mediana general de 2.50M Gs. frente a los 1.79M Gs. de las mujeres, poseyendo además los varones un techo salarial mucho más elevado y disperso.
2. **Brecha Educativa Creciente:** Aunque se cumple la teoría del capital humano (a mayor educación, mayor ingreso), la brecha salarial a favor de los

hombres se amplifica drásticamente en los niveles de educación terciaria y universitaria (más de 12 años de estudio).

3. **Doble Penalización Geográfica-Geográfica:** El cruce de variables evidencia que las mujeres rurales enfrentan la mayor vulnerabilidad, con una mediana de apenas **1,009,222 Gs.**, en franco contraste con los hombres urbanos (**2,988,696 Gs.**).

7. Hipótesis Preliminares (Hacia la Fase 2)

Debido a la asimetría confirmada, la Fase 2 empleará estadística inferencial no paramétrica para contrastar las siguientes hipótesis:

- **H1 (Test Principal):** H_0 : No hay diferencias en la distribución salarial entre hombres y mujeres ocupados. H_1 : Sí hay diferencias significativas (Se contrastará con Prueba U de Mann-Whitney, como indicado en la propuesta).
- **H2 (Impacto de Zona):** H_1 : Existen diferencias estadísticamente significativas en los ingresos asociadas a la zona de residencia (Urbana vs. Rural).
- **H3 (Impacto Educativo):** H_1 : Las medianas salariales varían significativamente según los años de estudio formal alcanzados (Se evaluará con Kruskal-Wallis).

8. Conclusión de la Fase 1

Tras ejecutar el proceso de comprensión, perfilado, limpieza (con bitácora de 14,422 registros limpios) y el análisis exploratorio (EDA) de los microdatos de la EPHC 2025, se han alcanzado satisfactoriamente los dos primeros objetivos específicos propuestos.

Respuesta a la pregunta de investigación (Hallazgos iniciales): Se constata con evidencia descriptiva que **sí existe una brecha salarial clara entre hombres y mujeres ocupados**. Asimismo, respondiendo a la segunda pregunta de la propuesta, se confirmó que **la brecha persiste y se agrava al observar la distribución entre regiones**, siendo las mujeres rurales el estrato más penalizado del mercado laboral. Finalmente, la educación demostró una influencia positiva fuerte ($p = 0,49$) al predecir el salario.

Limitaciones detectadas: El análisis se encuentra condicionado por la naturaleza declarativa del ingreso (sujeto a subdeclaración en sectores informales). Al ser un estudio transversal, se miden fuertes asociaciones estadísticas, pero no relaciones de causalidad temporal absoluta.

Decisiones para las fases siguientes: La asimetría de los datos convalida nuestra propuesta inicial de descartar el uso de estadística paramétrica (como t-Student clásica) en favor de métodos robustos no paramétricos (Mann-Whitney) para la **Fase 2**. Para la **Fase 3**, las variables `edad`, `anios_estudio`, `area_lbl` y `sexo_lbl` se perfilan como los predictores fundamentales para entrenar nuestros modelos de Machine Learning y predecir el salario.

9. Declaración de Uso de Asistentes de IA

Declaramos que para la elaboración y redacción del presente informe de la Fase 1, así como para la depuración y estructuración sintáctica del código en Python, se utilizó un asistente de inteligencia artificial (IA) como herramienta de apoyo complementaria. Dicho uso se limitó estrictamente a la consulta de sintaxis, optimización de bloques de código y mejora estilística de la redacción. Todas las decisiones metodológicas, la selección de variables, la interpretación crítica de los resultados estadísticos y el análisis sociológico de los gráficos fueron revisados, comprendidos y validados en su totalidad por los integrantes del Grupo 8.

10. Bibliografía y Recursos

1. Instituto Nacional de Estadística (INE) - Paraguay. *Encuesta Permanente de Hogares Continua (EPHC 2025)*. Microdatos oficiales.
2. Materiales de clase de la asignatura *Ciencia de Datos (Electiva)* - Prof. D.Sc. Margarita Ruiz Olazar, Facultad Politécnica, UNA.
3. McKinney, W. *Python for Data Analysis*, 3.^a edición. O'Reilly.
4. Documentación oficial de bibliotecas de Python: Pandas, Matplotlib, Seaborn, SciPy y Statsmodels.